

Inteligencia Artificial para previsão de rounds no Counter Strike - Global Offensive — Artificial Intelligence to predict rounds in Counter Strike - Global Offensive

Alisson da Silva Azevedo¹

¹Engenharia de Software – Instituto de Ensino Superior – (ICEV)
Teresina – PI – Brazil

alisson.azevedo@somosicev.com

Abstract. *This article aims to demonstrate, through predictive models, the prediction of a winning team in a round based on attributes such as team money, weapons, etc. Then, an experiment was carried out to compare the performance of different machine learning algorithms in prediction. The dataset consists of around 700 high-level tournament demos from 2019 to 2020.*

Resumo. *Este artigo tem como objetivo demonstrar por meio de modelos preditivos a previsão de uma equipe vencedora de uma rodada(round) baseado em atributos como dinheiro dos times, armas, etc. Em seguida, foi realizado um experimento para comparar o desempenho de diferentes algoritmos de aprendizado de máquina na previsão. O conjunto de dados consiste em cerca de 700 demos de torneios de alto nível de 2019 a 2020.*

1. Introdução

Os e-esportes, como são chamados os esportes eletrônicos que antes eram chamados de joguinhos de videogame vem crescendo bastante nos últimos anos onde foi colocado como os melhores esportes avaliados pelo grande potencial de aumento de receitas globalmente pela PwC em 2018 [Survey 2018], 2019 [Survey 2019] e 2020 [Survey 2020]), estimativas de receitas do mercado mundial subiram de 130 milhões de dólares para quase 1,1 bilhão de dólares americanos, fazendo com que as previsões para 2024 alcancem mais de 1,6 bilhão de dólares americanos [Statista 2021]. O crescimento tem despertado o interesse de organizações esportivas que procuram divergir.

Este artigo foi organizado por seções, na 1º apresenta-se uma contextualização sobre o problema, na 2º seção a metodologias utilizadas , na 3º os experimentos realizados, na 4º e ultima seção temos a conclusão e as considerações finais.

1.1. Contexto

O Counter Strike Global Offensive (CSGO) é um jogo de tiro tático, onde duas equipes contra-terroristas(CT) e terroristas(Tr) jogam em uma melhor de 30 rodadas, sendo cada rodada (round) de 1 minuto e 55 segundos. Há 5 jogadores em cada equipe (10 no total) e a primeira equipe a chegar a 16 rodadas vence o jogo. No início, um time joga como CT e o outro como Terrorista. Após 15 rodadas disputadas, as equipes trocam de lado. Existem 8 mapas diferentes em que um jogo pode ser jogado. Você vence uma rodada como Terrorista plantando a bomba e certificando-se de que ela exploda ou eliminando o outro time. Você ganha uma rodada como CT eliminando o outro time ou desarmando a bomba, caso ela tenha sido plantada. O objetivo deste artigo é mostrar por meio de experimentos a eficácia da aplicação de Machine Learning (ML) para a previsão de rounds no CSGO.

1.2. Problemática

Em cada round de uma partida de CSGO todos os jogadores recebem uma quantia de dinheiro para efetuarem a compra de itens como: armas, colete, granadas, defuse(para os CT's) que serão utilizadas para aquele round e esses itens podem ou não determinar a vitória do mesmo round.

As imagens abaixo apresentam screenshots (capturas de tela) de partidas de csgo.



Figura 1. Menu Rifles



Figura 2. Tela final

A figura (Figure 1) representa o menu de rifles de compra do jogador do lado contra-terrorista(CT) onde ela pode efetuar a compra de seus itens para jogar naquela rodada, ao lado esquerdo do menu fica a quantidade de dinheiro do jogador onde o mesmo tera aquela quantia máxima para gastar com a compra de seus armamentos naquele round. Cada arma possui um valor de dano, taxa de disparo, penetração em proteção, alcance de precisão, que fara diferença na hora de eliminar um inimigo.

Na figura (Figure 2) representa o final de uma partida onde a equipe que estava do lado CT vence o jogo por 16x12, na captura de tela é possível visualizar o número de vítimas representado pela letra V, número de assistências representado pela letra A e o número de mortes representado pela letra M de cada jogador presente na partida.

1.3. Economia

Nos pistol rounds, (rounds 1 e 16), cada jogador começa com 800 e, no decorrer da partida, cada tipo de arma concede uma quantia em dinheiro por kill: (Tabela 1).

Arma/Equipamento	Recompensa
Faca	\$1500
Pistola	\$300
CZ75	\$100
Submetralhadoras	\$600
P90	\$300
Escopetas	\$900
Rifles e metralhadoras	\$300
AWP	\$100
Granada	\$300
Zeus x27	\$0

Tabela 1. Recompensas

No final de cada round, o time vencedor recebe uma quantia em dinheiro que varia de acordo com o tipo de vitória: (Tabela 2).

Ação	Contraterroristas	Terroristas
Eliminando o time oponente	\$3250	\$3250 + \$300 se a bomba foi plantada
Desarmando a bomba	\$3500	\$0
Por tempo esgotado	\$3250	\$0
Detonando a bomba	\$0	\$3500

Tabela 2. Recompensa por Vitória

Para possibilitar viradas, o time que perde rounds também recebe um bônus de dinheiro que aumenta de acordo com a quantidade de rounds perdidos em sequência: (Tabela 3).

Derrota no pistol round (rounds 1 e 16)	\$1900
Derrota do primeiro round (que não seja o pistol)	\$1400
Derrota do segundo round consecutivo	\$1900
Derrota do terceiro round consecutivo	\$2400
Derrota do quarto round consecutivo	\$2900
Derrota do quinto round consecutivo	\$3400
Derrota do sexto round consecutivo em diante	\$3400

Tabela 3. Recompensa por Derrota

2. Metodologia

Os algoritmos de Machine Learning escolhidos foram o MLP (Perceptron multicamadas), Decision Tree (Árvore de decisão) que serão utilizados para a predição baseado no rótulo `round_winner` para cada snapshot do dataset.

Os algoritmos de Machine Learning escolhidos foram o MLP (Perceptron multicamadas) que é uma rede neural com uma ou mais camadas ocultas com um número indeterminado de neurônios. A camada oculta possui esse nome porque não é possível prever a saída desejada nas camadas intermediárias, Decision Tree (Árvore de decisão) que é método de aprendizado supervisionado não paramétrico usado para classificação e regressão onde seu objetivo é criar um modelo que preveja o valor de uma variável de destino aprendendo regras de decisão simples inferidas a partir dos recursos de dados.

2.1. Fonte de dados

Como fonte de dados, neste projeto foi utilizado como base de dados *CS:GO Round Winner Classification* disponível pela plataforma *Kaggle*, O conjunto de dados foi publicado originalmente pela [Skybox 2020] como parte de seu *CS:GO AI Challenge*, que aconteceu em 2020. O conjunto de dados consiste em cerca de 700 demos de torneios/campeonatos de alto nível do início de 2019 ao final de 2020. As rodadas de aquecimento e reinícios foram filtradas, e para as rodadas ao vivo restantes, um snapshot da rodada foi gravado a cada 20 segundos até que a rodada seja decidida. Após a publicação inicial, foi pré-processado e achatado para melhorar a legibilidade e facilitar o processamento dos algoritmos. O número total de snapshots é 122.411.

2.2. Compreendendo os Dados

Para melhor compreensão do dataset vamos dispor alguns atributos presentes no mesmo e uma breve descrição.

Atributo	Descrição
time_left	Tempo restante da rodada
ct_score	Quantidade de pontos da equipe Contra-terrorista
t_score	Quantidade de pontos da equipe Terrorista
map	Mapa da rodada
bomb_planted	bomba plantada ou não
ct_health	Quantidade da equipe Contra Terrorista com colete
t_health	Quantidade da equipe Terrorista com colete
ct_helmets	Quantidade Contra Terroristas com capacete
t_helmets	Quantidade Terroristas com capacete
ct_money	Total de dinheiro da equipe Contra-Terrorista
t_money	Total de dinheiro da equipe Terrorista
ct_defuse_kits	Quantidade de kits para defusar a bomba na equipe CT
ct_weapon_X	Armas compradas pela equipe CT
t_weapon_X	Armas compradas pela equipe TR
ct_grenade_X	Granadas compradas pela equipe CT
t_grenade_X	Granadas compradas pela equipe TR
round_winner	Equipe vencedora CT ou T

Tabela 4. Métricas usadas da base de dados

Na (Tabela 4) é possível visualizar atributos presentes no dataset.

3. Experimentos

Vamos dar uma olhada na distribuição de mapas no dataset e descobrir quem ganha mais nos mapas mais populares.




Figura 3. Mapas




Figura 4. Contra-terrorista x Terrorista

Como podemos ver, a distribuição de vitórias dependendo do mapa é ligeiramente diferente uma da outra.

Para todos os modelos foi necessário converter alguns atributos como a coluna `bomb_planted` que antes era somente `true` e `false` passou a ser números inteiros 0 ou 1, em seguida a coluna `round_winner` que antes mostrava CT(contra-terrorista) ou T(terrorista) foi substituído de T para 0, e CT para 1. Foram descartadas do dataset colunas com valor único. Os modelos foram rodados 10 vezes assim foi possível encontrar um boa acurácia mediante aos dados de teste.

3.1. MLP

O MLP (Perceptron multicamadas) que é uma rede neural com uma ou mais camadas ocultas com um número indeterminado de neurônios. A camada oculta possui esse nome porque não é possível prever a saída desejada nas camadas intermediárias. Em nosso experimento utilizaremos para processamento dos dados o `LabelEncoder` que ira encodar os rótulos do eixo y de 0 a `n_classes-1`, utilizaremos para escalonamento dos dados o `RobustScaler` onde ele escala as features usando estatísticas robustas para valores discrepantes, ou seja, remove a mediana e dimensiona os dados de acordo com o intervalo. Separamos 80% dos dados para treinamento e 20% para testes onde obtivemos em alguns momentos 80,04% de acurácia e em outros momentos 79,81%.

3.2. Decision Tree

O Decision Tree (Árvore de decisão) que é método de aprendizado supervisionado não paramétrico usado para classificação e regressão onde seu objetivo é criar um modelo que preveja o valor de uma variável de destino aprendendo regras de decisão simples inferidas a partir dos recursos de dados. No nosso estudo iremos inferir mapeando entre valores de 0 e 1 no rotulo de `round_winner`, utilizaremos para processamento dos dados o `LabelEncoder` que ira encodar os rótulos do eixo y de 0 a `n_classes-1` sendo assim possível prever as probabilidades da equipe vencedora. Para treinamento também separamos 80% dos dados e 20% para testes e obtivemos 82,12% de acurácia.

4. Conclusão

O experimento realizado utilizando os modelos de MLP e Decision Tree mostraram bons resultados baseado no tamanho da amostragem e no balanceamento dos dados. A acurácia dos modelos que foi obtida foram bem próximas enquanto o MLP nos deu em sua melhor acurácia 80,04%, o Decision Tree nos deu 82,12% uma pequena margem de 2% de diferença entre os modelos.

Modelo	Acurácia
MLP	80,04%
Decision Tree	82,12%

Tabela 5. Acurácia dos modelos

Desta forma, conclui-se que ambos os modelos são considerados aceitáveis para recomendação na predição de equipe vencedora de um round.

Referências

Skybox (2020). Skybox.

Statista (2021). Esports market revenue worldwide from 2019 to 2024.

Survey, P. S. (2018). Pwc's sports survey 2018 [online].

Survey, P. S. (2019). Pwc's sports survey 2019 [online].

Survey, P. S. (2020). Pwc's sports survey 2020 [online].